

Pavbot Podcast Brief

Temat: tech-news | Data: 2026-06-25 | Wygenerowano: 2026-06-25 09:05

DŁUGOŚĆ	SŁOWA
7:31	982
TTS	MODEL
piper	rhasspy/piper-voices:pl_PL-gosi-a-medium

Najważniejsze informacje

Dzień dobry.

To jest technologiczny przegląd Pavbota na dwudziestego piątego czerwca. Dziś mamy normalny odcinek oparty na porannym raporcie researchowym i świeżym sprawdzeniu publicznych źródeł. Główna oś dnia jest prosta: sztuczna inteligencja przestaje być tylko rozmową o modelach.

Pierwszy temat to OpenAI i Broadcom.

Firmy pokazały Jalapeño, pierwszy procesor OpenAI zaprojektowany specjalnie pod inference dużych modeli językowych. OpenAI opisuje go jako element wielopokoleniowej platformy compute, zoptymalizowanej pod ChatGPT, Codex, API i przyszłe produkty agentowe.

To ważne, bo inference jest miejscem, w którym AI naprawdę kosztuje: każde pytanie, każdy agentowy krok, każda odpowiedź w czasie rzeczywistym.

Jeśli OpenAI kontroluje nie tylko model, ale też chip, ruch pamięci, sieć i serving, może obniżyć koszt oraz opóźnienia w sposób niedostępny dla firmy, która kupuje gotową infrastrukturę. Trzeba jednak dodać ograniczenie: Jalapeño jest nadal na etapie próbek i pomiarów.

Drugi temat to Qualcomm.

Firma ogłosiła przejęcie Modular, rozszerzenie relacji z Hugging Face oraz wielogeneracyjną umowę z Metą na procesory data-center. W tle jest Dragonfly, czyli próba zbudowania stacku od urządzeń brzegowych po centra danych.

Dlaczego to ma znaczenie?

Bo rynek AI szuka alternatywy dla świata, w którym wszystko kręci się wokół jednej klasy GPU. Qualcomm ma naturalną pozycję na urządzeniach, ale teraz celuje wyżej: w software, developerów, orkiestrację i serwery. To nadal jest historia z przyszłością w cenie.

Kontekst redakcyjny

Dzień dobry. To jest technologiczny przegląd Pavbota na dwudziestego piątego czerwca. Dziś mamy normalny odcinek oparty na porannym raporcie researchowym i świeżym sprawdzeniu publicznych źródeł. Główna oś dnia jest prosta: sztuczna inteligencja przestaje być tylko rozmową o modelach. Staje się walką o cały system: chipy, pamięć, agentowe interfejsy, prawa dostępu, energię, wodę i kontrolę jakości pracy wykonywanej przez agentów.

Pierwszy temat to OpenAI i Broadcom. Firmy pokazały Jalapeño, pierwszy procesor OpenAI zaprojektowany specjalnie pod inference dużych modeli językowych. OpenAI opisuje go jako element wielopokoleniowej platformy compute, zoptymalizowanej pod ChatGPT, Codex, API i przyszłe produkty agentowe. Broadcom ma odpowiadać za implementację krzemu, networking i drogę do produkcji, a Celestica za część systemową.

To ważne, bo inference jest miejscem, w którym AI naprawdę kosztuje: każde pytanie, każdy agentowy krok, każda odpowiedź w czasie rzeczywistym. Jeśli OpenAI kontroluje nie tylko model, ale też chip, ruch pamięci, sieć i serving, może obniżyć koszt oraz opóźnienia w sposób niedostępny dla firmy, która kupuje gotową infrastrukturę. Trzeba jednak dodać ograniczenie: Jalapeño jest nadal na etapie próbek i pomiarów.

Źródła użyte

- [OpenAI: OpenAI and Broadcom unveil LLM-optimized inference chip](#)
- [Broadcom: OpenAI and Broadcom Unveil LLM-Optimized Intelligence Processor](#)
- [Business Wire / Qualcomm: Qualcomm to Acquire Modular](#)
- [Business Wire / Qualcomm and Hugging Face: Expand Relationship to Advance Open Developer-Driven AI](#)
- [Business Wire / Qualcomm and Meta: Strategic Multi-Generation Agreement on Data Center CPUs](#)
- [Qualcomm Investor Relations: data center and AI infrastructure strategy](#)
- [Google Blog: Introducing computer use in Gemini 3.5 Flash](#)
- [Google Blog: Interactions API general availability](#)
- [Google AI for Developers: Interactions API overview](#)
- [Moneycontrol / Reuters: Anthropic says Alibaba illicitly extracted Claude AI model capabilities](#)
- [Yahoo Finance / Reuters: Anthropic says Alibaba illicitly extracted Claude AI model capabilities](#)
- [Micron / GlobeNewswire: Micron Reports Record Results for Fiscal Q3 2026](#)
- [Micron Investor Relations: Micron and Anthropic announce strategic agreement](#)
- [House Energy and Commerce: Ratepayer Protection Act](#)
- [Rep. Kathy Castor: Ratepayer Protection Act](#)
- [NVIDIA Blog: 45C liquid cooling for AI factories](#)
- [GitHub Blog: How pull request limits are cutting down the noise](#)
- [Greptile: A statistical study of PRs opened on OpenClaw](#)

Uwagi źródłowe

Sprawdzone, niewykorzystane: Microsoft On the Issues: Scaling cybercrime disruption through innovation and AI (<https://blogs.microsoft.com/on-the-issues/2026/06/24/scaling-cybercrime-disruption-through-innovation-and-ai/>)

Sprawdzone, niewykorzystane: Anthropic: Introducing Claude Tag (<https://www.anthropic.com/news/introducing-claude-tag>)

Sprawdzone, niewykorzystane: Krea 2 Technical Report (<https://www.krea.ai/blog/krea-2-technical-report>)

Sprawdzone, niewykorzystane: Google Blog: Google DeepMind and A24 research partnership (<https://blog.google/innovation-and-ai/models-and-research/google-deepmind/deepmind-a24-research-partnership/>)

Sprawdzone, niewykorzystane: TOP500: LineShine Debuts No. 1 (<https://top500.org/news/lineshine-debuts-no-1-top500-enters-new-global-exascale-era/>)

Czytać razem ze źródłami

Dokument powstał lokalnie z pakietu podcastu. Fakty i interpretacje należy weryfikować z linkami źródłowymi.