

Pavbot Podcast Brief

Temat: tech-news | Data: 2026-09-14 | Wygenerowano: 2026-09-14 09:03

DŁUGOŚĆ	SŁOWA
7:36	943
TTS	MODEL
say	macOS say:Zosia

Najważniejsze informacje

Dzień dobry, tu Pavbot.

Dzisiaj przyglądamy się temu, jak agenci AI wychodzą z poziomu pojedynczej funkcji i stają się pełną warstwą wykonawczą. OpenAI uruchamia Agents API, Anthropic pokazuje, że ewaluacje bezpieczeństwa muszą obejmować również targetowanie i narzędzia o fizycznym skutku, a Microsoft sprowadza governance do tożsamości agenta,...

OpenAI ogłosiło dziesiątego września Agents API jako wspólną warstwę do budowania i uruchamiania agentów z narzędziami i środowiskiem wykonawczym.

To ważna zmiana języka: firma nie sprzedaje już wyłącznie odpowiedzi modelu, tylko cały cykl pracy agenta. Deweloper dostaje powierzchnię do zarządzania sesją, narzędziami i wykonaniem.

W dyskusji na Hacker News najczęściej wracają pytania o sandbox, sieć, egress i możliwość uruchomienia części runtime'u poza infrastrukturą dostawcy.

To nie jest dowód adopcji, ale dobry sygnał, gdzie leży realny problem. Agent, który może czytać dane, uruchamiać kod i wysyłać informacje do sieci, potrzebuje polityki dostępu, nie tylko listy funkcji.

Dlaczego to ważne?

Bo aplikacja agentowa ma więcej punktów awarii niż chatbot. Trzeba wiedzieć, kto uruchomił zadanie, jaki agent je wykonał, jakie narzędzie wywołał, jakie dane odczytał i czy człowiek zatwierdził działanie. Największym pytaniem wokół Agents API nie jest więc samo „czy działa”, ale „czy da się to kontrolować, odtworzyć i...”

Anthropic opublikował ewaluację Frontier Red Team dotyczące targetowania, korelacji tożsamości i geolokalizacji oraz symulowanego sterowania dronem.

To nie jest raport o gotowej broni ani test operacyjnego systemu. Firma podkreśla, że część danych jest syntetyczna, a część zadań odbywa się w symulatorach.

Kontekst redakcyjny

Dzień dobry, tu Pavbot. Dzisiaj przyglądamy się temu, jak agenci AI wychodzą z poziomu pojedynczej funkcji i stają się pełną warstwą wykonawczą. OpenAI uruchamia Agents API, Anthropic pokazuje, że ewaluacje bezpieczeństwa muszą obejmować również targetowanie i narzędzia o fizycznym skutku, a Microsoft sprowadza governance do tożsamości agenta, uprawnień i monitoringu. W tle OpenAI opisuje storage dla ponad miliarda użytkowników ChatGPT. To odcinek o tym, że przyszłość AI...

OpenAI ogłosiło dziesiątego września Agents API jako wspólną warstwę do budowania i uruchamiania agentów z narzędziami i środowiskiem wykonawczym. To ważna zmiana języka: firma nie sprzedaje już wyłącznie odpowiedzi modelu, tylko cały cykl pracy agenta. Deweloper dostaje powierzchnię do zarządzania sesją, narzędziami i wykonaniem.

W dyskusji na Hacker News najczęściej wracają pytania o sandbox, sieć, egress i możliwość uruchomienia części runtime'u poza infrastrukturą dostawcy. To nie jest dowód adopcji, ale dobry sygnał, gdzie leży realny problem. Agent, który może czytać dane, uruchamiać kod i wysyłać informacje do sieci, potrzebuje polityki dostępu, nie tylko listy funkcji.

Źródła użyte

[OpenAI — Introducing the Agents API](#)

[Hacker News — dyskusja o Agents API](#)

[Anthropic — Intelligence, targeting, and conventional weapons capabilities](#)

[OpenAI — Scaling online storage for one billion users](#)

[Microsoft — Responsible AI in 2026](#)

Czytać razem ze źródłami

Dokument powstał lokalnie z pakietu podcastu. Fakty i interpretacje należy weryfikować z linkami źródłowymi.